ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ THÔNG TIN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc Lập - Tự Do - Hạnh Phúc

ĐỀ CƯƠNG CHI TIẾT

TÊN ĐỀ TÀI: NGHIÊN CỨU HỆ THỐNG DỊCH MÁY CHO NGÔN NGỮ ÍT TÀI NGUYÊN: XÂY DỰNG BỘ DỮ LIỆU VÀ PHƯƠNG PHÁP TĂNG CƯỜNG DỮ LIỆU CHO TIẾNG TÀY

TÊN ĐỀ TÀI (Tiếng Anh): Research on Machine Translation Systems for Low-Resource Languages: A Dataset and Data Augmentation Methods for the Tay Language

Cán bộ hướng dẫn: ThS.Nguyễn Thành Luân

Thời gian thực hiện: Từ ngày 15/07/2026 đến ngày 15/10/2026

Sinh viên thực hiện:

Phạm Quốc Thắng – 25410304

Lê Minh Thiện – 25410313

Hệ đào tạo: Đào tạo từ xa

Nội dung đề tài:

1. Lý do chọn đề tài

Hiện nay, các ngôn ngữ dân tộc thiểu số tại Việt Nam có nguồn dữ liệu số và dữ liệu song ngữ rất hạn chế, gây khó khăn cho việc phát triển các hệ thống xử lý ngôn ngữ tự nhiên, đặc biệt là hệ thống dịch máy. Vì vậy, đề tài được thực hiện nhằm mục đích xây dựng một quy trình hoàn chỉnh bao gồm thu thập dữ liệu, chuẩn hóa, làm sạch, căn chỉnh câu song ngữ, tăng cường dữ liệu, huấn luyện mô hình dịch và triển khai ứng dụng minh họa. Kết quả của nghiên cứu không chỉ mang lại giá trị học thuật mà còn có tiềm năng ứng dụng thực tiễn trong việc hỗ trợ cộng đồng sử dụng ngôn ngữ ít tài nguyên tiếp cận thông tin dễ dàng hơn.

2. Mục tiêu đề tài

Mục tiêu tổng quát: Xây dựng và đánh giá một hệ thống dịch máy cho một cặp ngôn ngữ ít tài nguyên (Việt ↔ Tày), dựa trên mô hình ngôn ngữ NLLB và bộ dữ liệu song ngữ do nhóm tự xây dựng.

Mục tiêu cụ thể:

- Khảo sát các phương pháp dịch máy hiện đại.
- Xây dựng bộ dữ liệu song ngữ từ nguồn VOV4 và các tài liệu công khai.

- Phát triển công cụ xử lý, căn chỉnh dữ liệu và fine-tune mô hình NLLB.
- Đánh giá chất lượng mô hình bằng các thang đo như BLEU, SacreBLEU, chrF và COMET.
- Tích hợp công nghệ nhận dạng giọng nói Whisper để thử nghiệm quy trình dịch giọng nói (S2T) và xây dựng Web Application minh họa.

3. Đối tượng và phạm vi nghiên cứu

- **Đối tượng nghiên cứu:** Cặp ngôn ngữ Việt ↔ Tày. mô hình dịch máy đa ngôn ngữ NLLB và công nghệ nhận dạng giọng nói Whisper.
- **Phạm vi nghiên cứu:** Tập trung vào việc dịch các câu, đoạn văn ngắn trong lĩnh vực tin tức, văn hóa và đời sống. Hệ thống dịch giọng nói được triển khai ở mức độ minh họa khái niệm (proof of concept). Đề tài không đặt mục tiêu thương mại, không dịch hội thoại theo thời gian thực quy mô sản phẩm và không cam kết bao phủ mọi biến thể phương ngữ.

4. Phương pháp thực hiện

Đề tài thực hiện thông qua 9 giai đoạn chính:

- **Giai đoạn 1 & 2:** Khảo sát bài toán, xác định cặp ngôn ngữ, sau đó xây dựng công cụ (crawler) để thu thập dữ liệu thô từ VOV4 và các tài liệu song ngữ.
- **Giai đoạn 3:** Làm sạch, chuẩn hóa Unicode, căn chỉnh câu song ngữ, và chia tách dữ liệu thành các tập train/validation/test.
- **Giai đoạn 4 & 5:** Chạy thử NLLB gốc để tạo baseline, sau đó tiến hành tinh chỉnh (fine-tune) mô hình NLLB toàn phần hoặc bằng LoRA/PEFT trên bộ dữ liệu vừa chuẩn bị.
- **Giai đoạn 6:** Tăng cường dữ liệu bằng back-translation hoặc sinh dữ liệu AI có kiểm soát và thực hiện ablation study.
- **Giai đoạn 7 & 8:** Xây dựng pipeline tích hợp Whisper (chuyển âm thanh thành văn bản đích thông qua NLLB) và phát triển Web Application (sử dụng React, FastAPI, PyTorch...) cho phép nhập văn bản/giọng nói để dịch thuật.
- **Giai đoạn 9:** Đánh giá tự động, đánh giá thủ công, phân tích lỗi (từ hiếm, sai căn chỉnh, v.v.) và hoàn thiện báo cáo.

5. Kết quả mong đợi (Sản phẩm bàn giao)

- Bộ dữ liệu song ngữ Việt ↔ Tày.
- Các công cụ hỗ trợ thu thập, chuẩn hóa và căn chỉnh dữ liệu.
- Mô hình NLLB đã được fine-tune cùng bộ script huấn luyện, suy luận.
- Web Application minh họa có tích hợp module dịch văn bản và dịch giọng nói bằng Whisper.
- Báo cáo đồ án tốt nghiệp, slide bảo vệ và tài liệu hướng dẫn.

6. Kế hoạch thực hiện

6.1 Lộ trình thời gian

Tuần	Nội dung công việc
1 - 5	Khảo sát tài liệu, xác định cặp ngôn ngữ. Thu thập dữ liệu và xây dựng crawler.
6 - 8	Làm sạch, chuẩn hóa dữ liệu, xây dựng baseline.
9 - 13	Fine-tune NLLB. thực hiện tăng cường dữ liệu và thực nghiệm.
14 - 16	Tích hợp Whisper tạo module dịch giọng nói và xây dựng Web Application.
17 - 18	Đánh giá mô hình, phân tích lỗi, hoàn thiện báo cáo và bảo vệ đồ án.

6.2 Phân công nhiệm vụ

- **Lê Minh Thiện:** Khảo sát mô hình, xây dựng pipeline huấn luyện, chịu trách nhiệm tinh chỉnh (fine-tune) NLLB, quản lý thực nghiệm và tích hợp mô hình vào backend.
- **Phạm Quốc Thắng:** Khảo sát, thu thập, quản lý dữ liệu; phát triển Web Application, module xử lý âm thanh (Whisper) và điều phối công tác đánh giá.

Xác nhận của CBHD (Ký tên và ghi rõ họ tên) **Nguyễn Thành Luân**	**TP. HCM, ngày 15 tháng 07 năm 2026** **Sinh viên** (Ký tên và ghi rõ họ tên) **Phạm Quốc Thắng Lê Minh Thiện**